



تمرین سوم درس یادگیری ماشین
دکتر باباعلی

سیدعلیرضا مولوی

فهرست مطالب

۱	۱	LDA برای داده های چند کلاسه
۱	۱.۱	مدل محاسباتی
۱	۲.۱	ماتریس پراکندگی درون کلاسی
۱	۳.۱	ماتریس پراکندگی بین کلاسی
۱	۴.۱	تابع معیار
۲	۵.۱	محاسبه λ بهینه
۳	۲	سوال دوم
۳	۱.۲	داده ها
۳	۲.۲	مدل محاسباتی
۳	۳.۲	محاسبه ماتریس پراکندگی بین کلاسی
۴	۴.۲	محاسبه ماتریس پراکندگی بین کلاسی
۴	۵.۲	محاسبه λ بهینه
۵	۳	سوال سوم
۵	۱.۳	داده ها
۵	۲.۳	نظیر کردن داده ها به فضای ۱ بعدی
۶	۳.۳	مسئله دسته بندی
۶	۴.۳	بررسی نتایج

۱ LDA برای داده های چند کلاسه

۱.۱ مدل محاسباتی

فرض کنیم که داده های ما شامل $K \geq 2$ کلاس باشند. معادله $f(x; \omega)$ را به صورت معادله ۱ تعریف می کنیم.

$$f(x; \omega) = \omega^T x \quad (۱)$$

در واقع تابع $f(x; \omega)$ داده را بر روی ابرصفحه^۱ ω نظیر می کند. توجه اگر هدف کاهش به بعد d' باشد، کافی است که $\omega \in R^{(d, d')}$ در نظر بگیریم.

۲.۱ ماتریس پراکندگی درون کلاسی

برای محاسبه ماتریس پراکندگی درون کلاسی ابتدا طبق معادله ۲ میانگین تمام داده ها را محاسبه می کنیم، سپس بر اساس معادله ۳ میانگین هر کلاس را جداگانه بدست می آوریم، و سپس طبق معادله ۴، که N_k تعداد اعضای کلاس k اند، ماتریس پراکندگی درون کلاسی را محاسبه می کنیم.

$$\mu = \frac{1}{N} \sum_i x^{(i)} \quad (۲)$$

$$\mu_k = \frac{1}{N_k} \sum_{i: y_i=k} x^{(i)} \quad (۳)$$

$$S_B = \sum_k N_k (\mu - \mu_k)(\mu - \mu_k)^T \quad (۴)$$

۳.۱ ماتریس پراکندگی بین کلاسی

برای محاسبه ماتریس پراکندگی بین کلاسی ابتدا ماتریس پراکندگی هر کلاس را طبق معادله ۵ محاسبه می کنیم و سپس طبق معادله ۶ با هم جمع می کنیم.

$$s_k^2 = \sum_{i: y_i=k} (\mu_k - x^{(i)})(\mu_k - x^{(i)})^T \quad (۵)$$

$$S_w = \sum_{i=1}^K s_i^2 \quad (۶)$$

۴.۱ تابع معیار

تابع معیار $J(\omega)$ به صورت معادله ۱۰ تعریف می کنیم.

$$\mu_l = \omega^T \mu \quad (۷)$$

$$\mu'_k = \omega^T \mu_k \quad (۸)$$

$$s_k'^2 = \sum_{i: y_i=k} (\omega^T \mu_k - \omega^T x^{(i)})(\omega^T \mu_k - \omega^T x^{(i)})^T \quad (۹)$$

$$J(\omega) = \frac{\sum_k N_k (\mu'_k - \mu')(\mu'_k - \mu')^T}{\sum_k s_k'^2} \quad (۱۰)$$

^۱HyperPlane

اکنون سعی می کنیم که معادلات را ساده تر کنیم. با فاکتورگیری به معادله ۱۲ می رسم.

$$J(\omega) = \frac{\omega^T (\sum_k N_k (\mu_k - \mu)(\mu_k - \mu)^T) \omega}{\omega^T (\sum_k s_k^2) \omega} \quad (۱۱)$$

$$J(\omega) = \frac{\omega^T S_B \omega}{\omega^T S_w \omega} \quad (۱۲)$$

۵.۱ محاسبه ω بهینه

هدف ما بیشینه کردن تابع معیار $J(\omega)$ است.

$$\omega^* = \operatorname{argmax}_{\omega} J(\omega) \quad (۱۳)$$

اکنون برای بدست آوردن ω بهینه کافی است، مشتق تابع $J(\omega)$ را محاسبه کرده و مقدار مشتق را برابر 0 قرار داده و ω بهینه را استخراج کنیم. معادلات کاملاً مشابه معادلات درس داده شده در بخش LDA است.

$$\frac{\partial J(\omega)}{\partial \omega} = 0 \implies S_B \omega = \lambda S_w \omega \quad (۱۴)$$

$$\implies S_w^\dagger S_B \omega = \lambda \omega \quad (۱۵)$$

$$\lambda = J(\omega) = \frac{\omega^T S_B \omega}{\omega^T S_w \omega} \quad (۱۶)$$

با مشتق گیری به معادله ۱۵ می رسم که در آن S_w^\dagger شبه معکوس است؛ معادله ۱۵ در واقع معادله بردار ویژه است و با حل آن می توانیم مقدار بهینه ω را بدست بیاوریم. هدف بیشینه کردن $J(\omega) = \lambda$ است، بنابراین ω بردار ویژه بزرگترین مقدار ویژه معادله ۱۵ است (اگر $\omega \in R^{d'}$ باشد، آنگاه ω برابر d' بزرگترین بردارهای ویژه است).

۲ سوال دوم

برای حل از روش چن کلاسه استفاده شده است.
توجه ماتریس پراکندگی بین کلاسی در روش چن کلاسه با روش دو کلاسه متفاوت است ولی در نهایت جواب های بدست آمده یکسان است.


۱.۲ داده ها

$$X_0 = \left\{ \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \end{pmatrix} \right\} \quad (۱۷)$$

$$X_1 = \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \begin{pmatrix} -1 \\ -1 \end{pmatrix} \right\} \quad (۱۸)$$

$$(۱۹)$$

شکل ۱: داده های آموزشی در فضای ۲ بعدی



۲.۲ مدل محاسباتی

با توجه به روش ذکر شده مدل محاسباتی را به صورت معادله ۲۰ تعریف می کنیم. در واقع تابع $f(\cdot; \omega)$ نقطه x را بر روی خط ω نظیر می کند.

$$f(x; \omega) = \omega^T x \quad (۲۰)$$

۳.۲ محاسبه ماتریس پراکندگی بین کلاسی

توجه ماتریس پراکندگی بین کلاسی در روش چن کلاسه با روش دو کلاسه متفاوت است ولی در نهایت جواب های بدست آمده یکسان است.

$$\mu = \begin{pmatrix} 0.14285714 \\ 0 \end{pmatrix} \quad (21)$$

$$\mu_0 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad (22)$$

$$\mu_1 = \begin{pmatrix} 1 \\ -0.5 \end{pmatrix} \quad (23)$$

اکنون مقادیر بالا را در معادله ۴ جایگذاری می کنیم.

$$S_B = 3(\mu - \mu_0)(\mu - \mu_0)^T + 4(\mu - \mu_1)(\mu - \mu_1)^T \quad (24)$$

$$= \begin{pmatrix} 3.85714286 & 0 \\ 0 & 0 \end{pmatrix} \quad (25)$$

۴.۲ محاسبه ماتریس پراکندگی بین کلاسی

با استفاده از معادلات ۵ و ۶ مقادیر زیر را حساب می کنیم.

$$s_0^2 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} \quad (26)$$

$$s_1^2 = \begin{pmatrix} 3 & 2 \\ 2 & 4 \end{pmatrix} \quad (27)$$

$$S_w = \begin{pmatrix} 5 & 4 \\ 4 & 6 \end{pmatrix} \quad (28)$$


۵.۲ محاسبه ω بهینه

با جایگذاری مقادیر محاسبه شده S_B و S_w در معادلات ۲۵، ۲۸ در معادله ۱۵ و حل معادله مقدار ویژه، مقدار بهینه زیر بدست می آید. در شکل ۲ داده ها و خط LDA رسم شده است.

$$\omega = \begin{pmatrix} 0.83205029 \\ -0.5547002 \end{pmatrix} \quad (29)$$

$$J(\omega) = 1.6530612244897962 \quad (30)$$

شکل ۲: شکل چپ: داده ها در فضای دو بعدی و خط قرمز رنگ خط LDA است. شکل راست: داده ها نگاشت شده بر روی خط LDA




۳ سوال سوم

۱.۳ داده ها

داده ها دارای دو ویژگی اند و هر داده به کلاس 0 و یا 1 تخصیص داده شده است. بنابراین مسئله دسته بندی دوتایی^۲ است. داده ها به دو دسته، داده های آموزشی و داده های تست تقسیم شده است. تعداد داده های آموزشی ۴۰۰۰ و تعداد داده های تست ۲۰۰۰ است. در شکل ۳ داده ها را مشاهده می کنید.

شکل ۳: شکل راست: داده های تست. شکل چپ: داده های آموزشی



۲.۳ نظیر کردن داده ها به فضای ۱ بعدی

با استفاده از الگوریتم LDA ما داده ها به فضای یک بعدی کاهش داده ایم (شکل ۴). مقدار بهینه

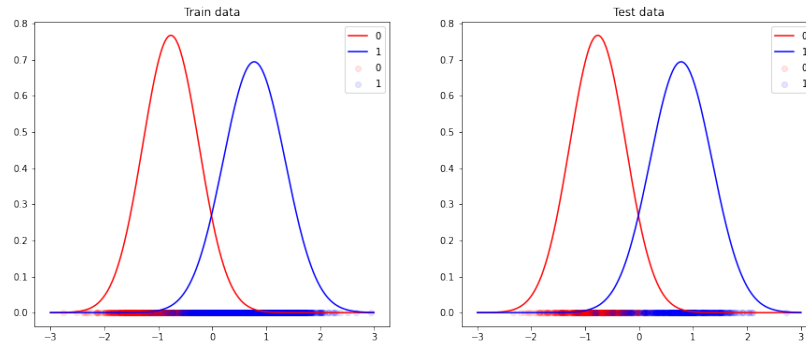
$$\omega = \begin{pmatrix} 0.9708 \\ 0.2310 \end{pmatrix}$$

است. مقدار تابع معیار $J(\omega)$ برای داده ها به صورت زیر است:

$$J_{train}(\omega) = 1.9894 \quad J_{test}(\omega) = 2.1813$$

Binary Classification^۲

شکل ۴: شکل راست: داده های تست. شکل چپ: داده های آموزشی



۳.۳ مسئله دسته بندی^۳

فرض می کنیم که داده ها از یک توزیع احتمالاتی تولید می شوند $(x, y) \sim P$. مقدار بهینه y را به صورت زیر تعریف می کنیم:

$$y^* = \operatorname{argmax}_y P(y|x; \theta) \quad (۳۱)$$

$$\propto \operatorname{argmax}_y P(x|y; \theta) P(y; \theta) \quad (۳۲)$$

$$\propto \operatorname{argmax}_y \log P(x|y; \theta) + \log P(y; \theta) \quad (۳۳)$$

فرض می گیریم که هر داده از یک توزیع گاوسی چند متغیره^۴ تولید می شود و مقدار پیشین^۵ $P(y; \theta)$ را میانگین y در نظر می گیریم.

$$P(x|y; \theta) \sim N(x; \mu_y, \Sigma_y) \quad (۳۴)$$

$$P(y; \theta) = \frac{N_y}{N} \quad (۳۵)$$

$$\mu_y = \frac{1}{N_y} \sum_{i, y_i=y} x^{(i)} \quad (۳۶)$$

$$\Sigma_y(i, j) = \operatorname{Cov}(x_i, x_j) \quad (۳۷)$$

در شکل ۴ نمودار های گاوسی بر روی داده رسم شده اند.

۴.۳ بررسی نتایج

مقدار دقت پس از آموزش:

$$\text{Train Accuracy} = 0.922 \quad \text{Test Accuracy} = 0.932$$

با توجه به شکل ۴ بخشی از داده ها توسط هر دو توزیع گاوسی پوشانده شده اند و مدل معمولاً به اشتباه این داده ها را دسته بندی می کند. در شکل ۵ داده هایی که اشتباه دسته بندی شده اند رو مشاهده می کنید.

^۳ Classification Problem
^۴ Multivariate normal distribution
^۵ Prior

شکل ۵: شکل راست: داده های تست. شکل چپ: داده های آموزشی
 داده های که اشتباه دسته بندی شده اند به رنگ مشکی اند.

